Algorithme semi-supervisé : Fixmatch

Fares Ernez Baptiste Aussel Albin Cintas



Introduction

Plan

- 1) Présentation du jeu de données et de la méthode
- 2) Fonction pertes et optimiseurs
- 3) Comparaison des résultats

Présentation du jeu de données

1. Dataset de 9975 images 64*64.









- 2. 475 images sont associées à un label, 9500 ne le sont pas.
- 3. Le dataset possède 95 type d'animaux différents
 - a. ex: marmotte, macaque, fourmi, girafe, tortue, araigné, hippopotame, corcodile, ours brun, ours noir ...
- 4. 2850 images pour le test

Présentation du jeu de données CIFAR-10

1. Dataset de 50000 images 32*32.










2. 2500 images sont associées à un label, 47500 ne le sont pas.

- 3. Le jeu CIFAR-10 possède 10 classes différentes
 - a. avion, cerf, chien, chat, oiseau, cheval, camion, grenouille, voiture, bateau
- 4. 10000 images pour le test

Présentation de l'algorithme




Les augmentations de données : faible

Simple stratégie d'augmentation flip and shift .

On retourne l'image avec une probabilité 0.5 et on décale l'image de 12.5 % verticalement et horizontalement





Les augmentations de données : forte

(AutoAugment) *

En amont : Définition de policies et sub-policies (paires)

Sub-policy 0 (Invert,0.1,7) (Contrast,0.2,6)

probabilité
d'application magnitude

entraîné avec
RL

| 1111 | Operation 1 | Operation 2 |
|---------------|-----------------------|-----------------------|
| Sub-policy 0 | (Invert, 0.1, 7) | (Contrast, 0.2, 6) |
| Sub-policy 1 | (Rotate, 0.7, 2) | (TranslateX, 0.3,9) |
| Sub-policy 2 | (Sharpness, 0.8, 1) | (Sharpness, 0.9,3) |
| Sub-policy 3 | (ShearY, 0.5, 8) | (TranslateY, 0.7,9) |
| Sub-policy 4 | (AutoContrast, 0.5,8) | (Equalize, 0.9,2) |
| Sub-policy 5 | (ShearY, 0.2, 7) | (Posterize, 0.3,7) |
| Sub-policy 6 | (Color, 0.4, 3) | (Brightness, 0.6,7) |
| Sub-policy 7 | (Sharpness, 0.3,9) | (Brightness, 0.7,9) |
| Sub-policy 8 | (Equalize, 0.6, 5) | (Equalize, 0.5,1) |
| Sub-policy 9 | (Contrast, 0.6, 7) | (Sharpness, 0.6,5) |
| Sub-policy 10 | (Color, 0.7, 7) | (TranslateX, 0.5,8) |
| Sub-policy 11 | (Equalize, 0.3,7) | (AutoContrast, 0.4,8) |
| Sub-policy 12 | (TranslateY,0.4,3) | (Sharpness, 0.2, 6) |
| Sub-policy 13 | (Brightness, 0.9,6) | (Color, 0.2, 8) |
| Sub-policy 14 | (Solarize, 0.5,2) | (Invert, 0.0, 3) |
| Sub-policy 15 | (Equalize, 0.2,0) | (AutoContrast, 0.6,0) |
| Sub-policy 16 | (Equalize, 0.2,8) | (Equalize, 0.6,4) |
| Sub-policy 17 | (Color, 0.9,9) | (Equalize, 0.6, 6) |
| Sub-policy 18 | (AutoContrast, 0.8,4) | (Solarize, 0.2,8) |
| Sub-policy 19 | (Brightness, 0.1,3) | (Color, 0.7, 0) |
| Sub-policy 20 | (Solarize, 0.4,5) | (AutoContrast, 0.9,3) |
| Sub-policy 21 | (TranslateY,0.9,9) | (TranslateY, 0.7,9) |
| Sub-policy 22 | (AutoContrast, 0.9,2) | (Solarize, 0.8,3) |
| Sub-policy 23 | (Equalize, 0.8,8) | (Invert, 0.1, 3) |
| Sub-policy 24 | (TranslateY,0.7,9) | (AutoContrast, 0.9,1) |

Table 7. AutoAugment policy found on reduced CIFAR-10.

^{*:&}quot;AutoAugment : Learning Augmentation Strategies from Data". Ekin D. Cubuk , Barret Zoph, Dandelion Man é, Vijay Vasudevan

Les augmentations de données : forte (AutoAugment) *

Résultats:

| 1111 11 | Operation 1 | Operation 2 |
|---------------|-----------------------|-----------------------|
| Sub-policy 0 | (Invert, 0.1, 7) | (Contrast, 0.2, 6) |
| Sub-policy 1 | (Rotate, 0.7,2) | (TranslateX, 0.3,9) |
| Sub-policy 2 | (Sharpness, 0.8, 1) | (Sharpness, 0.9,3) |
| Sub-policy 3 | (ShearY, 0.5, 8) | (TranslateY, 0.7,9) |
| Sub-policy 4 | (AutoContrast, 0.5,8) | (Equalize, 0.9,2) |
| Sub-policy 5 | (ShearY, 0.2, 7) | (Posterize, 0.3,7) |
| Sub-policy 6 | (Color, 0.4, 3) | (Brightness, 0.6,7) |
| Sub-policy 7 | (Sharpness, 0.3,9) | (Brightness, 0.7,9) |
| Sub-policy 8 | (Equalize, 0.6, 5) | (Equalize, 0.5,1) |
| Sub-policy 9 | (Contrast, 0.6,7) | (Sharpness, 0.6,5) |
| Sub-policy 10 | (Color, 0.7, 7) | (TranslateX,0.5,8) |
| Sub-policy 11 | (Equalize, 0.3,7) | (AutoContrast, 0.4,8) |
| Sub-policy 12 | (TranslateY,0.4,3) | (Sharpness, 0.2, 6) |
| Sub-policy 13 | (Brightness, 0.9,6) | (Color, 0.2, 8) |
| Sub-policy 14 | (Solarize, 0.5,2) | (Invert, 0.0, 3) |
| Sub-policy 15 | (Equalize, 0.2,0) | (AutoContrast, 0.6,0) |
| Sub-policy 16 | (Equalize, 0.2,8) | (Equalize, 0.6,4) |
| Sub-policy 17 | (Color, 0.9,9) | (Equalize, 0.6, 6) |
| Sub-policy 18 | (AutoContrast, 0.8,4) | (Solarize, 0.2,8) |
| Sub-policy 19 | (Brightness, 0.1, 3) | (Color, 0.7, 0) |
| Sub-policy 20 | (Solarize, 0.4,5) | (AutoContrast, 0.9,3) |
| Sub-policy 21 | (TranslateY,0.9,9) | (TranslateY, 0.7,9) |
| Sub-policy 22 | (AutoContrast, 0.9,2) | (Solarize, 0.8,3) |
| Sub-policy 23 | (Equalize, 0.8,8) | (Invert, 0.1, 3) |
| Sub-policy 24 | (TranslateY,0.7,9) | (AutoContrast, 0.9,1) |



Une sub-policy choisie aléatoirement

Table 7. AutoAugment policy found on reduced CIFAR-10.

^{*:&}quot;AutoAugment : Learning Augmentation Strategies from Data". Ekin D. Cubuk , Barret Zoph, Dandelion Man é, Vijay Vasudevan

Fonction perte

$$\mathbf{L} = \ell_s + \lambda_u \ell_u$$

Avec:

•
$$\ell_s = \frac{1}{B} \sum_{b=1}^{B} \mathrm{H}(p_b, p_\mathrm{m}(y \mid \alpha(x_b)))$$
 l'entropie croisée sur les données labellisées

•
$$\ell_u = \frac{1}{\mu B} \sum_{b=1}^{\mu B} \mathbbm{1}(\max(q_b) \ge \tau) \, \mathrm{H}(\hat{q}_b, p_\mathrm{m}(y \mid \mathcal{A}(u_b)))$$
 l'entropie croisée entre les données non labellisées fortement augmentées et les pseudo-labels


- $q_b=p_{
 m m}(y\mid lpha(u_b))$ la prédiction du modèle sur une donnée non labellisées faiblement augmentées qu'on retient si l'arg max depasse le threshold au
- ullet un hyperparamètre à étudier et μ le ratio de données non labellisées


Optimiseurs

Essais des optimiseurs Adam et SGD avec threshold = 0.9 et $\lambda = \begin{cases} 0 \text{ si } t < 20 \\ (t - 20) \times \frac{1}{40} \text{ si } t < 60 \\ 1 \text{ sinon.} \end{cases}$


Optimiseur Adam


learning rate = 3e-3







learning rate = 3e-4





learning rate = 3e-5









Optimiseurs

Essais des optimiseurs Adam et SGD avec threshold = 0.9 et $\lambda = \begin{cases} 0 \text{ si } t < 20 \\ (t - 20) \times \frac{1}{40} \text{ si } t < 60 \\ 1 \text{ sinon.} \end{cases}$


Optimiseur SGD


learning rate = 3e-3 et momentum = 0.5







learning rate = 3e-4 et momentum = 0.5





learning rate = 3e-5 et momentum = 0.5





Comparaison des résultats


1) variation des lambdas


$$\lambda(t) = e^{t/Nbepochs} \qquad \lambda = \begin{cases} 0 \text{ si } t < 20 \\ (t-20) \times \frac{1}{40} \text{ si } t < 60 \\ 1 \text{ simon.} \end{cases}$$
Training and validation accuracy


Traini

Comparaison des résultats


2) variation du threshold














thre =
$$0.95$$

acc = 0.53

Conclusion

- Nécessité d'avoir un jeu de données important
- Meilleur résultat avec
 - Adam
 - \circ LR = 3e-4
 - \circ lambda = exp(t/(2*Nbepochs))
 - \circ threshold = 0.95
- Amélioration par rapport au modèle simplement supervisé de ~+3%